

Governança integrada habilita consulta em linguagem natural sobre ocupação de leitos hospitalares

Gabriel Arcenio Rahal Marostica

Orientador: José Bernardo Neto

MBA em Engenharia de Software — USP/Esalq, 2026

Resumo

Este trabalho propõe e implementa uma arquitetura de referência para Conversational Analytics em ambiente hospitalar, com governança integrada e aderente à LGPD, às normas da ANVISA e às diretrizes da ANPD, aplicada ao domínio de ocupação de leitos. O protótipo organiza um pipeline de dados em camadas (Bronze, Silver e Gold) sob um motor de tradução de perguntas em linguagem natural para SQL, com controles de governança na entrada e na saída e avaliação por execution match. Toda a pesquisa usa dados exclusivamente sintéticos e execução determinista. Os resultados preliminares confirmam a anonimização da camada exposta ao modelo, o funcionamento dos controles de governança e os primeiros números de acurácia do motor de linguagem, acompanhados de uma análise de erros que distingue limitações da métrica e da governança de erros de cálculo do modelo.

Palavras-chave: Text-to-SQL; conformidade regulatória; dados sintéticos; saúde digital; execution match.

1. Introdução

As interfaces em linguagem natural para bancos de dados são um campo de pesquisa maduro (AFFOLTER; STOCKINGER; BERNSTEIN, 2019). Em particular, a tradução de perguntas em linguagem natural para consultas SQL (Text-to-SQL) é objeto de estudo consolidado, com benchmarks de referência como o Spider (YU et al., 2018) e, no domínio clínico, o EHRSQL (LEE et al., 2022), e tem sido profundamente transformada pelos modelos de linguagem de grande porte (SHI et al., 2024). A adoção desses modelos para consulta a dados clínicos em linguagem natural promete ampliar o acesso de gestores e equipes assistenciais à informação, mas esbarra em um obstáculo central: a governança dos dados e do próprio modelo costuma ser tratada de forma fragmentada, separada da arquitetura de dados. Em saúde, essa fragmentação é crítica, pois envolve dados pessoais sensíveis e um marco regulatório exigente, composto pela Lei Geral de Proteção de Dados (BRASIL, 2018), pelas

normas da ANVISA aplicáveis a software como dispositivo médico (ANVISA, 2022) e pelas diretrizes da Autoridade Nacional de Proteção de Dados (ANPD, 2024).

Este trabalho parte da hipótese de que é possível integrar a governança à arquitetura de dados, de ponta a ponta, sem comprometer a utilidade da consulta em linguagem natural. Propõe-se uma arquitetura de referência em quatro camadas, na qual a anonimização, o controle de acesso por perfil, a validação da consulta e a auditoria atravessam todo o fluxo, da pergunta do usuário à resposta entregue. O domínio escolhido para implementação e avaliação é a ocupação de leitos hospitalares, e toda a pesquisa utiliza dados exclusivamente sintéticos, o que elimina na origem o risco de exposição de dados reais e permite que a arquitetura seja replicada por outras instituições.

O objetivo geral é demonstrar, por meio de um protótipo funcional, a viabilidade dessa arquitetura integrada e avaliar a acurácia do motor de tradução de perguntas em SQL sobre dados sintéticos, sob a hipótese de acurácia superior a 80%. Como objetivos específicos, o trabalho se propõe a: (a) revisar a literatura sobre Conversational Analytics, Text-to-SQL e governança de modelos de linguagem; (b) mapear os requisitos regulatórios aplicáveis (LGPD, ANVISA e ANPD); (c) projetar a arquitetura técnica, da ingestão ao Lakehouse e ao motor com guardrails; (d) desenvolver o modelo de governança, contemplando controle de acesso, rastreabilidade, anonimização e validação; e (e) implementar e avaliar o protótipo sobre dados sintéticos.

2. Metodologia

A pesquisa caracteriza-se como um estudo de caso instrumental apoiado no desenvolvimento de um protótipo. Os métodos são descritos a seguir na mesma ordem em que os resultados são apresentados.

2.1 Geração do dataset sintético

Os dados foram gerados de forma determinista e materializados na camada Bronze do pipeline. A geração emprega a biblioteca Faker com localidade pt_BR, governada por uma semente única, e ancora-se em uma data de referência fixa da simulação. O ambiente representa um hospital de grande porte, com oito unidades, duzentos leitos e seiscentos pacientes, e abrange uma janela histórica de noventa dias de ocupação diária. Dados pessoais identificáveis (nome, CPF e data de nascimento) são inseridos

de propósito na Bronze, para que a anonimização realizada na camada seguinte seja real e demonstrável.

2.2 Arquitetura em quatro camadas

A arquitetura organiza o sistema em quatro camadas encadeadas: o pipeline Lakehouse (Bronze, Silver e Gold), a governança de entrada, o motor de tradução de perguntas em SQL e a validação de saída. O pipeline foi implementado em DuckDB. A camada Bronze recebe os dados brutos; a Silver limpa e anonimiza; e a Gold expõe métricas agregadas, sendo a única camada visível ao motor de linguagem. As camadas internas, Bronze e Silver, permanecem inacessíveis ao modelo.

2.3 Modelo de governança

A governança foi concebida como defesa em profundidade, alinhada às boas práticas de gestão de risco de sistemas de inteligência artificial (NIST, 2023). Na entrada, seis guardrails verificam que a consulta candidata é uma única instrução somente leitura, sem comandos de escrita ou administrativos, restrita às tabelas Gold autorizadas ao perfil do usuário, e a execução ocorre sobre uma conexão de banco somente leitura. Na saída, a validação confere o aterramento da consulta contra o schema Gold conhecido, bloqueia qualquer coluna de resultado cujo nome corresponda a um campo sensível e registra cada pergunta e cada resposta em uma trilha de auditoria, com o evento da interação.

2.4 Conformidade regulatória

Os requisitos regulatórios foram mapeados a controles concretos da arquitetura, à camada responsável e à sua situação de implementação. O mapeamento cobre a LGPD, as normas da ANVISA aplicáveis a software como dispositivo médico e as diretrizes da ANPD, totalizando onze requisitos, e evidencia que a governança atravessa as quatro camadas e não se restringe ao motor de inteligência artificial.

2.5 Método de avaliação

A avaliação adota a métrica de execution match, consolidada em benchmarks de Text-to-SQL como o Spider (YU et al., 2018), o EHRSQL (LEE et al., 2022) e o BIRD (LI et al., 2023): a consulta gerada pelo modelo e a consulta de referência são executadas e seus conjuntos de resultados são comparados após normalização (arredondamento numérico com tolerância de duas casas, datas em formato ISO e linhas ordenadas). Além da acurácia, são medidos dois indicadores de governança: a taxa de aprovação

das consultas pelos guardrails e a completude do log de auditoria. O conjunto de avaliação reúne dezoito perguntas em português, com a respectiva consulta de referência sobre a Gold, cobrindo quatro tipos de pergunta operacional: status atual, métrica por unidade, série histórica e interações por faixa etária. O motor existe em duas implementações intercambiáveis: o oráculo, que devolve a consulta de referência e serve apenas para autoteste da tubulação, e o modelo de linguagem real, que gera os números reportados.

2.6 Reprodutibilidade e integridade

A reprodutibilidade foi assegurada por construção. Uma semente fixa e uma data de referência fixa controlam toda a geração de dados e as consultas que mencionam datas relativas; o ambiente foi fixado em uma versão específica de Python, com dependências travadas por versão e uma imagem reprodutível cuja base é fixada por digest. A integração contínua executa, a cada alteração, apenas o motor oráculo, sem chave de API e sem custo. Como princípio de integridade, os números de acurácia provêm somente da execução real do modelo, com a separação explícita entre o oráculo (autoteste) e o modelo (desempenho).

3. Resultados Preliminares

Apresentam-se a seguir os resultados parciais verificáveis. Os números provêm de execução determinista e são reprodutíveis.

3.1 Geração do dataset sintético

A geração produziu, de forma determinista, oito unidades, duzentos leitos, seiscentos pacientes, 2.012 internações e 18.000 registros de ocupação diária. No dia de referência (31 de maio de 2026), o hospital apresentava 150 leitos ocupados, 42 livres e 8 bloqueados, o que corresponde a uma taxa de ocupação de 75,0%. A coerência foi verificada: as 150 internações ativas igualaram exatamente os 150 leitos ocupados no dia de referência. A transformação para as camadas Silver e Gold confirmou a anonimização: a tabela de pacientes da Silver não contém nome, CPF nem data de nascimento; o identificador do paciente foi substituído por um pseudônimo derivado de hash com salt, sem colisão entre os seiscentos pacientes; e a data de nascimento deu lugar à faixa etária, em linha com os princípios de anonimização e generalização de atributos identificadores (SWEENEY, 2002). A Tabela 1 resume o snapshot de ocupação por unidade.

Unidade	Total	Ocup.	Livres	Bloq.	Taxa (%)
Cardiologia	25	18	6	1	72,0
Pediatria	25	17	6	2	68,0
Clínica Médica	25	21	4	0	84,0
Cirurgia Geral	25	23	2	0	92,0
Ortopedia	25	16	5	4	64,0
Neurologia	25	20	5	0	80,0
Oncologia	25	17	7	1	68,0
Pronto-Socorro	25	18	7	0	72,0
Hospital	200	150	42	8	75,0

Tabela 1. Ocupação por unidade no dia de referência (camada Gold). Fonte: o autor.

3.2 Arquitetura de referência em quatro camadas

A arquitetura foi documentada e implementada nas quatro camadas, com fluxo rastreável da pergunta do usuário à resposta entregue. Apenas a camada Gold, agregada, é exposta ao modelo; as camadas Bronze e Silver permanecem inacessíveis. A documentação modular do protótipo consolida essa arquitetura como

o principal artefato de referência do trabalho, com decisões, regras críticas, controles e requisitos regulatórios identificados e rastreáveis ao código.

3.3 Modelo de governança de entrada e saída

Os controles de governança foram implementados e verificados por testes. A eficácia foi observada na avaliação com o modelo real: em duas perguntas, o modelo produziu uma consulta que retornaria o número correto, porém a partir de uma tabela fora do escopo autorizado ao perfil de enfermagem. Em ambos os casos, o guardrail de escopo por perfil bloqueou a execução antes que a consulta tocasse o banco, evidenciando que o controle de acesso por finalidade opera como projetado. A validação de saída e a auditoria da resposta completam a barreira final de governança.

3.4 Conformidade regulatória

O mapeamento entre os onze requisitos regulatórios e os controles da arquitetura foi concluído, associando cada requisito a um controle implementado, à camada responsável e à sua situação. O resultado demonstra que a governança é transversal às quatro camadas, e não um componente isolado do motor de inteligência artificial.

3.5 Avaliação

A tubulação de avaliação foi exercitada de ponta a ponta com o motor oráculo. Para as dezoito perguntas, o execution match resultou em 100%, a aprovação na governança em 100% e a completude do log em 100%. Esse resultado é um autoteste da tubulação e não representa o desempenho do modelo.

A primeira execução com o modelo de linguagem real forneceu os primeiros números de acurácia. Sobre o conjunto inicial de dez perguntas, o execution match estrito foi de 60,0%. Após a correção de uma inconsistência interna do harness de medição (o arredondamento embutido na consulta de referência) e a ampliação do conjunto para dezoito perguntas, o execution match foi de 61,1%. A estabilidade do valor com o conjunto quase dobrado indica que a medida não foi fortuita. Esse patamar é coerente com a literatura, na qual mesmo modelos avançados alcançam acurácia limitada em benchmarks realistas, a exemplo dos cerca de 40% relatados para o ChatGPT no BIRD (LI et al., 2023). A Tabela 2 reporta as duas execuções lado a lado.

Execução	Conjunto	AVAL-001	AVAL-002	AVAL-003
Bruta (1ª)	10 perguntas	60,0%	90,0%	100,0%
Refinada	18 perguntas	61,1%	88,9%	100,0%

Tabela 2. Indicadores de avaliação do modelo real, bruto e refinado. Fonte: o autor.

A análise dos resultados não correspondentes da execução refinada mostrou que a maior parte não decorreu de erro de cálculo do modelo, conforme a Tabela 3. Das dezoito perguntas, apenas uma apresentou erro genuíno de cálculo (filtragem de um valor categórico com a caixa incorreta, resultando em conjunto vazio). Duas foram bloqueadas pela governança, por acessarem tabela fora do escopo do perfil, embora o valor numérico estivesse correto. As quatro restantes divergiram apenas na forma do resultado, com colunas adicionais ou formato distinto, refletindo a sensibilidade conhecida do execution match estrito à projeção. Manteve-se o execution match estrito como métrica primária, sem a introdução de métricas alternativas mais permissivas; a categorização dos erros acompanha o número.

Categoria	Itens	Natureza
Bloqueio pela governança	2	Valor correto, porém via tabela fora do escopo do perfil; barrado pelo guardrail.
Forma / projeção	4	Valores corretos, com colunas extras ou formato distinto; limitação do execution match.
Erro de cálculo	1	Filtragem de valor categórico com caixa incorreta (value linking).
Corretas	11	Conjunto de resultados idêntico ao da referência.

Tabela 3. Categorização dos resultados da execução refinada (18 perguntas). Fonte: o autor.

3.6 Reprodutibilidade e integridade

A reprodutibilidade foi confirmada: a mesma configuração reproduz os mesmos dados e números, inclusive entre as versões 3.12 e 3.14 do Python. A integração contínua executa o autoteste a cada alteração, sem chave e sem custo, e a imagem reprodutível fixa o ambiente por completo. Os números de acurácia foram coletados apenas em execução real do modelo, com a metodologia de medição decidida antes da reexecução e os valores bruto e refinado reportados lado a lado, preservando a integridade dos resultados.

4. Considerações Finais (parciais)

Os resultados preliminares confirmam a viabilidade técnica da arquitetura integrada: o pipeline de dados é coerente e anonimizado, os controles de governança funcionam de ponta a ponta e a avaliação produz números reais e verificáveis. Sob execution match estrito, a hipótese de acurácia superior a 80% ainda não se confirma; a análise de erros, contudo, indica que o teto é puxado pela forma do resultado e pela

governança, e não pelo raciocínio do modelo, já que apenas um dos dezoito casos correspondeu a erro de cálculo. Como continuidade, preveem-se o tratamento de value linking (exposição dos valores categóricos do schema ao modelo ou comparação textual sem distinção de caixa), a discussão da métrica sensível à forma e a ampliação e estratificação do conjunto de avaliação por tipo de pergunta e por perfil.

Referências

- AFFOLTER, K.; STOCKINGER, K.; BERNSTEIN, A. A comparative survey of recent natural language interfaces for databases. *The VLDB Journal*, v. 28, n. 5, p. 793-819, 2019. DOI: 10.1007/s00778-019-00567-8. Disponível em: <https://doi.org/10.1007/s00778-019-00567-8>. Acesso em: 10 jun. 2026.
- AGÊNCIA NACIONAL DE VIGILÂNCIA SANITÁRIA (ANVISA). Resolução da Diretoria Colegiada – RDC nº 657, de 24 de março de 2022. Dispõe sobre a regularização de software como dispositivo médico (Software as a Medical Device – SaMD). Brasília, DF: Anvisa, 2022. Disponível em: <https://anvisalegis.datalegis.net/action/ActionDatalegis.php?acao=abrirTextoAto&tipo=RDC&numeroAto=00000657&seqAto=000&valorAno=2022&orgao=RDC/DC/ANVISA/MS>. Acesso em: 10 jun. 2026.
- AUTORIDADE NACIONAL DE PROTEÇÃO DE DADOS (ANPD). Radar tecnológico: inteligência artificial generativa. Brasília, DF: ANPD, 2024. Disponível em: https://www.gov.br/anpd/pt-br/documentos-e-publicacoes/documentos-de-publicacoes/radar_tecnologico_ia_generativa_anpd.pdf. Acesso em: 10 jun. 2026.
- BRASIL. Lei nº 13.709, de 14 de agosto de 2018. Lei Geral de Proteção de Dados Pessoais (LGPD). Brasília, DF: Presidência da República, 2018. Disponível em: https://www.planalto.gov.br/ccivil_03/_ato2015-2018/2018/lei/l13709.htm. Acesso em: 10 jun. 2026.
- LEE, G.; HWANG, H.; BAE, S.; KWON, Y.; SHIN, W.; YANG, S.; SEO, M.; KIM, J.-Y.; CHOI, E. EHRSQL: a practical text-to-SQL benchmark for electronic health records. In: *Advances in Neural Information Processing Systems (NeurIPS) – Datasets and Benchmarks Track*, 2022. Disponível em: <https://arxiv.org/abs/2301.07695>. Acesso em: 10 jun. 2026.

LI, J.; HUI, B.; QU, G. et al. Can LLM already serve as a database interface? A big bench for large-scale database grounded text-to-SQLs (BIRD). In: Advances in Neural Information Processing Systems (NeurIPS) – Datasets and Benchmarks Track, 2023. Disponível em: <https://arxiv.org/abs/2305.03111>. Acesso em: 10 jun. 2026.

NATIONAL INSTITUTE OF STANDARDS AND TECHNOLOGY (NIST). Artificial Intelligence Risk Management Framework (AI RMF 1.0). NIST AI 100-1. Gaithersburg, MD: NIST, 2023. Disponível em: <https://nvlpubs.nist.gov/nistpubs/ai/nist.ai.100-1.pdf>. Acesso em: 10 jun. 2026.

SHI, L.; TANG, Z.; ZHANG, N.; ZHANG, X.; YANG, Z. A survey on employing large language models for text-to-SQL tasks. ACM Computing Surveys, 2024. Disponível em: <https://arxiv.org/abs/2407.15186>. Acesso em: 10 jun. 2026.

SWEENEY, L. k-anonymity: a model for protecting privacy. International Journal of Uncertainty, Fuzziness and Knowledge-Based Systems, v. 10, n. 5, p. 557-570, 2002. DOI: 10.1142/S0218488502001648. Disponível em: <https://doi.org/10.1142/S0218488502001648>. Acesso em: 10 jun. 2026.

YU, T.; ZHANG, R.; YANG, K.; YASUNAGA, M.; WANG, D.; LI, Z.; MA, J.; LI, I.; YAO, Q.; ROMAN, S.; ZHANG, Z.; RADEV, D. Spider: a large-scale human-labeled dataset for complex and cross-domain semantic parsing and text-to-SQL task. In: Proceedings of the 2018 Conference on Empirical Methods in Natural Language Processing (EMNLP), 2018. Disponível em: <https://arxiv.org/abs/1809.08887>. Acesso em: 10 jun. 2026.

Apêndice A — Arquitetura de referência em quatro camadas




Figura A.1. Fluxo de uma pergunta pelas quatro camadas. Fonte: o autor.

Camada	Responsabilidade	Documentação
1. Pipeline Lakehouse	Ingestão (Bronze), limpeza e anonimização (Silver), métricas (Gold)	camadas/01
2. Governança de entrada	Perfil, registro da pergunta e conformidade antes de executar	camadas/02
3. Motor Text-to-SQL	Pergunta em português para SQL somente leitura na Gold	camadas/03
4. Validação de saída	Aterramento, filtro de campo sensível e auditoria da resposta	camadas/04

Quadro A.1. Síntese das quatro camadas. Fonte: o autor.

Apêndice B — Requisitos regulatórios e controles

Requisito	Controle na arquitetura	Camada
REG-LGPD-001	Anonimização na Silver: remoção de nome, CPF e data de nascimento; derivação de faixa etária	Silver
REG-LGPD-002	Pseudonimização de id_paciente por hash; nenhuma identificação direta sobrevive à Silver	Silver
REG-LGPD-003	Apenas a Gold, agregada, é exposta ao motor; Bronze e Silver inacessíveis (CTRL-GOV-004)	Gold
REG-LGPD-004	Perfis autorizam apenas tabelas Gold específicas (CTRL-GOV-005)	Entrada
REG-LGPD-005	Guardrails CTRL-GOV-001 a 003 e 006: SQL única somente leitura, sem escrita/admin, conexão read-only	Entrada
REG-LGPD-006	Filtro de saída CTRL-VALID-002: bloqueia coluna com nome de campo sensível	Saída
REG-LGPD-007	Auditoria CTRL-AUD-001: registro de toda pergunta e resposta	Auditoria
REG-ANPD-001	Aterramento CTRL-VALID-001: toda tabela citada deve existir no schema Gold conhecido	Saída
REG-ANPD-002	Escopo restrito por perfil, execução somente leitura e registro integral	Entrada e Auditoria
REG-ANVISA-001	Guardrails versionados, auditoria e reprodutibilidade do software	Transversal
REG-PESQ-001	Determinismo (SEED, SIM_TODAY); separação motor LLM (números) vs oráculo (autoteste)	Transversal

Quadro B.1. Mapeamento de requisitos regulatórios para controles e camadas. Fonte: o autor.